



UNIVERSIDADE FEDERAL DO AMAZONAS
INSTITUTO DE CIÊNCIAS EXATAS E TECNOLOGIA-
ICET



GEOVANNA BEATHRYZ
GUSTAVO SOUZA
IASMIM BRAGA
JEAN BARAÚNA
KAIO SOBRAL
PEDRO JHEIVISON

TRABALHO PRÁTICO 2 – IHC E MACHINE LEARNING
Classificação Supervisionada Aplicada a Problemas de
Usabilidade

GEOVANNA BEATHRYZ
GUSTAVO SOUZA
IASMIM BRAGA
JEAN BARAÚNA
KAIO SOBRAL
PEDRO JHEIVISON

TRABALHO PRÁTICO 2 – IHC E MACHINE LEARNING

Classificação Supervisionada Aplicada a Problemas de
Usabilidade

Relatório do Trabalho Prático 2 (TP2) apresentado
à disciplina de Interação Humano-Computador
(IHC), do Instituto de Ciências Exatas e Tecnologia
(ICET) da Universidade Federal do Amazonas
(UFAM), como requisito parcial para a obtenção
de nota.

Prof. Dr. Andrey Rodrigues

Sumário

RELATÓRIO FINAL	3
1. Contexto e Motivação	3
2. Atributos Preditores	3
3. Classe-Alvo	4
4. Regras usadas para gerar a classe-alvo	4
5. Descrição da Base Sintética	4
6. Descrição dos Experimentos no Weka	5
6.1 Análise Visual dos Dados	5
7. Resultados dos Experimentos de Classificação	6
7.1 ZeroR	6
7.2 OneR	6
7.3 J48 (Árvore de Decisão)	7
7.4 Naive Bayes	7
7.5 IBk (k-Nearest Neighbors)	7
7.6 Tabela Comparativa dos Resultados	8
8. Análise do Modelo da Árvore de Decisão (J48)	8
9. Resultados	10
10. Análise crítica dos resultados em relação ao domínio de IHC	14
CONCLUSÃO	16

RELATÓRIO FINAL

1. Contexto e Motivação

O problema de classificação foi formulado no contexto de um aplicativo hipotético chamado "**Agenda Fácil**", projetado para profissionais autônomos (como manicures, barbeiros e personal trainers) gerenciarem seus agendamentos de clientes. A principal proposta de valor do aplicativo é ser simples e eficiente, minimizando a chance de erros comuns em agendamentos manuais.

A motivação para este estudo é investigar se é possível treinar um modelo de machine learning para classificar automaticamente o nível de usabilidade de uma sessão de uso, com base em dados quantitativos da interação do usuário. Tal modelo poderia, no futuro, ajudar desenvolvedores a identificar pontos de atrito na interface e a validar melhorias de design de forma automatizada, prevendo se uma interação foi positiva ou negativa.

2. Atributos Preditores

Para treinar o modelo, foram selecionados 5 atributos preditores que representam diferentes aspectos de uma tarefa central do aplicativo: "realizar um novo agendamento". Esses atributos foram escolhidos por serem métricas clássicas de usabilidade, como tempo de tarefa e número de erros.

- **tempo_para_agendar (Numérico)**: Tempo total, em segundos, que o usuário levou para concluir a tarefa de agendamento. Mede a *eficiência*.
- **passos_ate_concluir (Numérico)**: Número total de cliques ou toques necessários para finalizar o agendamento. Mede a *complexidade do fluxo de interação*.
- **usou_lista_clientes (Nominal: {sim, não})**: Indica se o usuário utilizou a funcionalidade de selecionar um cliente já cadastrado, uma ação que representa um caminho mais eficiente.
- **ativou_lembrete (Nominal: {sim, não})**: Verifica se o usuário ativou a função de lembrete automático, indicando engajamento com funcionalidades chave do sistema.

- **erros_no_fluxo (Numérico):** Quantidade de erros cometidos durante o processo, como clicar em um botão desabilitado ou tentar agendar em um horário já ocupado. Mede a **eficácia**.

3. Classe-Alvo

A classe-alvo, ou seja, o atributo que desejamos prever, foi definida para representar a qualidade geral da usabilidade da sessão.

- **Nome da Classe:** nível usabilidade
- **Valores Possíveis:** {Alta, Media, Baixa}
- **Tipo de Problema:** Multiclasse

Cada valor representa uma avaliação da interação: **Alta** indica uma experiência fluida e eficiente; **Média** indica que a tarefa foi concluída, mas com alguma dificuldade; e **Baixa** indica uma experiência frustrante e ineficiente.

4. Regras usadas para gerar a classe-alvo

Usabilidade Alta: $\text{tempo_agendar} < 45$ segundos E $\text{erros_fluxo} = 0$ Usabilidade Baixa: $\text{tempo_agendar} > 120$ segundos OU $\text{erros_fluxo} > 2$ Usabilidade Média: Casos que não se enquadram nas condições anteriores.

5. Descrição da Base Sintética

A base de dados utilizada neste trabalho, denominada `base_sintetica.arff`, foi gerada artificialmente para simular o comportamento de usuários no aplicativo "Agenda Fácil". O objetivo foi criar um conjunto de dados controlado para treinar um modelo de Machine Learning capaz de classificar o nível de usabilidade de uma interação com base em métricas de desempenho.

A geração foi guiada por um conjunto de regras explícitas, detalhadas na proposta do projeto. A base de dados contém 200 instâncias e 6 atributos, sendo 5 atributos preditores e 1 atributo-alvo (a classe).

Os atributos são descritos a seguir:

tempo_agendar (Numérico): Representa o tempo total, em segundos, que o usuário levou para concluir um agendamento.

passos_concluir (Numérico): Indica o número de cliques ou toques que o usuário realizou para finalizar a tarefa.

usou_lista_clientes (Nominal: {sim, nao}): Informa se o usuário utilizou a lista de clientes pré-cadastrados, um recurso que otimiza o fluxo.

ativou_lembrete (Nominal: {sim, nao}): Verifica se o usuário ativou funcionalidades adicionais, como lembretes para o agendamento.

erros_fluxo (Numérico): Quantifica o número de erros cometidos pelo usuário durante o processo de agendamento.

nivel_usabilidade (Nominal: {Alta, Media, Baixa}): Este é o atributo-alvo (classe). Ele classifica a interação do usuário em três níveis de usabilidade, com base nas regras de geração de dados.

Esse conjunto de dados serve como alicerce para os experimentos, permitindo a aplicação de algoritmos de classificação para identificar padrões que se correlacionam com uma experiência de usuário positiva ou negativa.

6. Descrição dos Experimentos no Weka

Nesta etapa, foi utilizada a ferramenta Weka Explorer para a análise exploratória e experimental da base de dados `base_sintetica.arff`.

6.1 Análise Visual dos Dados

Inicialmente, os dados foram carregados na aba “Visualize”, onde foi gerada uma Matriz de Gráficos de Dispersão (Plot Matrix) para observar a distribuição dos atributos e suas possíveis correlações. As instâncias foram coloridas de acordo com a variável-alvo `nivel_usabilidade`, conforme a legenda:

- Azul escuro: Alta usabilidade
- Vermelho: Média usabilidade
- Ciano: Baixa usabilidade

A partir dessa análise, foi possível identificar os seguintes padrões:

- **Correlação entre atributos numéricos**: Observou-se uma correlação positiva entre os atributos `tempo_agendar` e `passos_concluir`. As instâncias formam uma tendência diagonal, indicando que tarefas que exigem mais passos também demandam mais tempo. A classe Alta (azul escuro) concentra-se em valores baixos de tempo e passos, a classe Média (vermelho) apresenta valores intermediários, e a classe Baixa (ciano) predomina em valores elevados.
- **Separação das classes**: Os atributos numéricos demonstraram uma boa capacidade de distinguir as classes de usabilidade. `tempo_agendar` e

passos _concluir baixos tendem a indicar usabilidade Alta, enquanto valores altos apontam para usabilidade Baixa. O atributo erros_fluxo também se mostrou um forte preditor: 0 erros está associado à predominância da classe Alta, 1 a 2 erros à Média , e acima de 2 erros à Baixa.

- **Influência dos atributos categóricos:** Verificou-se que a maioria das instâncias da classe Alta ocorre quando usou listaclientes e ativou lembrete possuem valor "sim", sugerindo que o uso dessas funcionalidades está associado a uma melhor percepção de usabilidade.

A exploração inicial indicou padrões visuais bem definidos e uma separação clara entre as classes, o que sugere que os algoritmos de aprendizado de máquina devem ser capazes de aprender regras de classificação com alta precisão.

7. Resultados dos Experimentos de Classificação

Para avaliar a capacidade de predição do nível de usabilidade, foram treinados e testados cinco algoritmos de classificação: ZeroR, OneR, J48, Naive Bayes e IBk. A base de dados foi dividida com a abordagem *Percentage Split*, utilizando 66% dos dados para treino. A seguir, são apresentados os resultados detalhados para cada modelo.

7.1 ZeroR

O ZeroR, um classificador de linha de base, previu sempre a classe majoritária "Media".

- **Acurácia:** 46,9697%

Matriz de Confusão:

a	b	c	<-- classified as
0	18	0	a = Alta
0	31	0	b = Media
0	17	0	c = Baixa

7.2 OneR

O OneR (One Rule) gerou uma regra de classificação baseada no atributo que melhor prediz a classe-alvo.

- **Acurácia:** 98,4848%

Matriz de Confusão:

a b c <-- classified as
17 1 0 | a = Alta
0 31 0 | b = Media
0 0 17 | c = Baixa

7.3 J48 (Árvore de Decisão)

O J48 é uma implementação do algoritmo C4.5 que gera uma árvore de decisão para classificar as instâncias.

- **Acurácia:** 100%

Matriz de Confusão:

a b c <-- classified as
18 0 0 | a = Alta
0 31 0 | b = Media
0 17 0 | c = Baixa

7.4 Naive Bayes

Este classificador probabilístico utiliza o teorema de Bayes com a suposição de independência entre os atributos.

- **Acurácia:** 100%

Matriz de Confusão:

a b c <-- classified as
18 0 0 | a = Alta
0 31 0 | b = Media
0 17 0 | c = Baixa

7.5 IBk (k-Nearest Neighbors)

O IBk é um classificador baseado em instâncias. Foi utilizado com a configuração padrão ($k=1$).

- **Acurácia:** 98,4848%

Matriz de Confusão:

a b c <-- classified as
18 0 0 | a = Alta
0 30 1 | b = Media
0 0 17 | c = Baixa

7.6 Tabela Comparativa dos Resultados

Algoritmo	Acurácia	Instâncias Corretamente Classificadas
ZeroR	46,97%	31 / 66
OneR	98,48%	65 / 66
IBk (kNN)	98,48%	65 / 66
J48	100%	66 / 66
Naive Bayes	100%	66 / 66

8. Análise do Modelo da Árvore de Decisão (J48)

Uma das principais vantagens do algoritmo J48 é a alta interpretabilidade do seu modelo. A árvore de decisão gerada revela um conjunto de regras hierárquicas e claras que o algoritmo "descobriu" a partir dos dados, fornecendo insights valiosos sobre a relação entre os atributos e o nível de usabilidade.

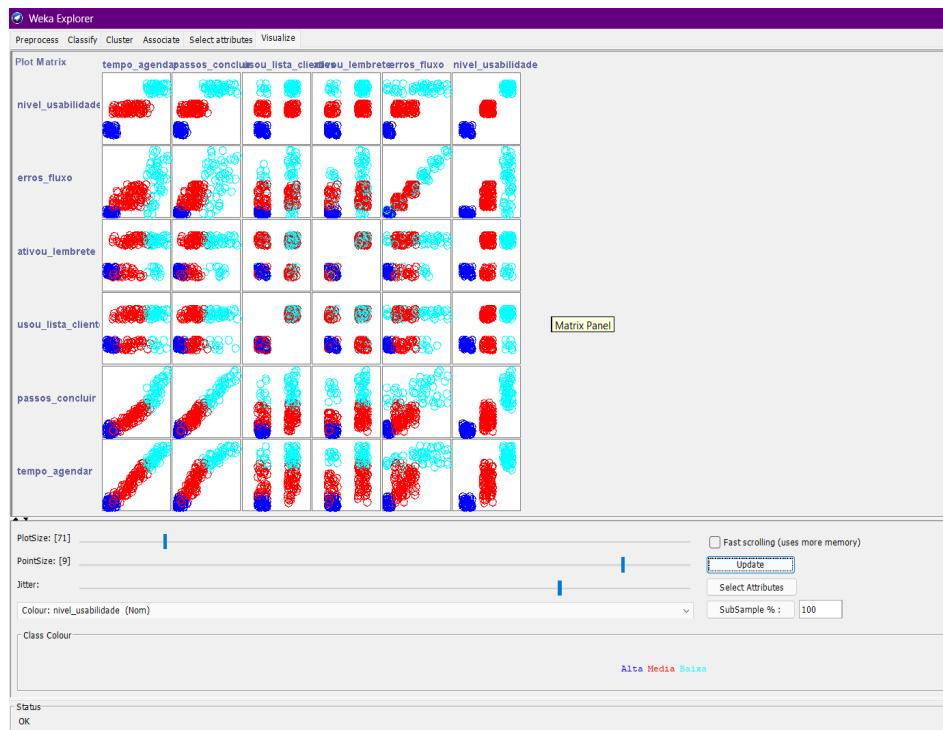
- O Fator Decisivo: Tempo na Tarefa (tempo_agendar)
A raiz da árvore, e portanto o atributo mais importante, é o tempo_agendar. O modelo aprendeu um limiar crítico de 120 segundos. Se o tempo para concluir a tarefa excede esse valor, a usabilidade é incondicionalmente classificada como Baixa. Isso demonstra que, no contexto do sistema avaliado, a eficiência é o principal pilar da percepção de usabilidade.
- O Diferencial para a Qualidade: Ausência de Erros (erros_fluxo)
Para tarefas concluídas em tempo aceitável (≤ 120 segundos), o fator determinante para a qualidade da experiência passa a ser a ocorrência de erros. O modelo aprendeu que:
 - Se o usuário comete pelo menos um erro (> 0), a usabilidade é classificada como **Média**.

- Apenas quando a tarefa é concluída de forma eficiente e sem nenhum erro ($<=0$), a usabilidade atinge o nível **Alta**.

As regras extraídas da árvore de decisão validam empiricamente conceitos fundamentais de Interação Humano-Computador. O modelo confirmou que uma boa usabilidade é uma função direta da eficiência (baixo tempo para completar a tarefa) e da eficácia (ausência de erros). A clareza do modelo J48 não só resultou em uma acurácia perfeita, mas também forneceu uma explicação lógica e alinhada com a teoria de IHC para o problema de classificação proposto.

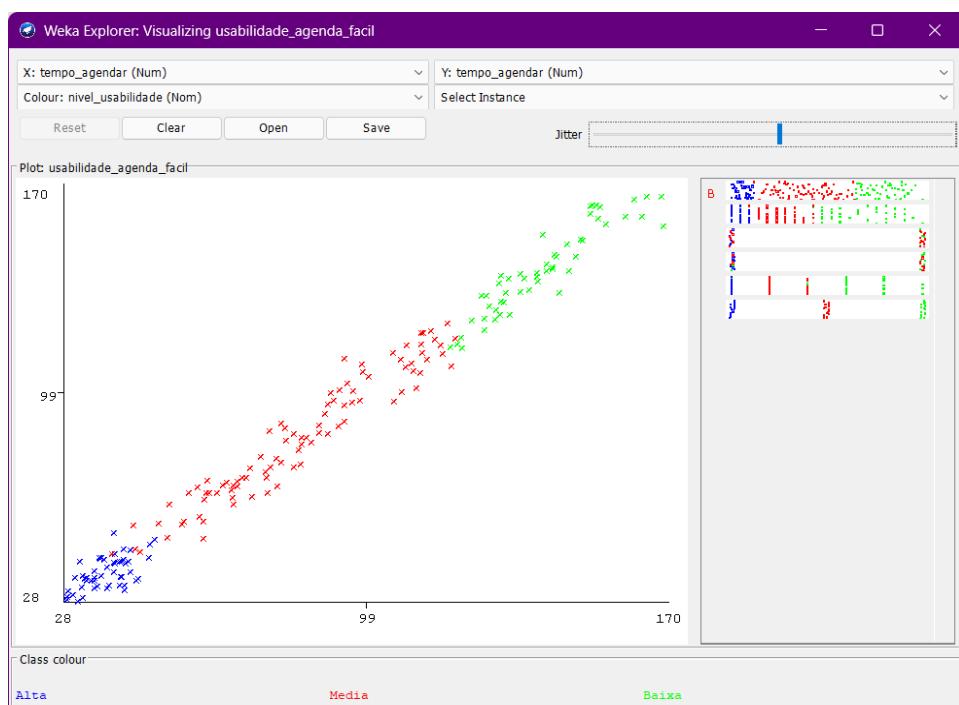
9. Resultados

Figura 1 - Aba “Visualize”



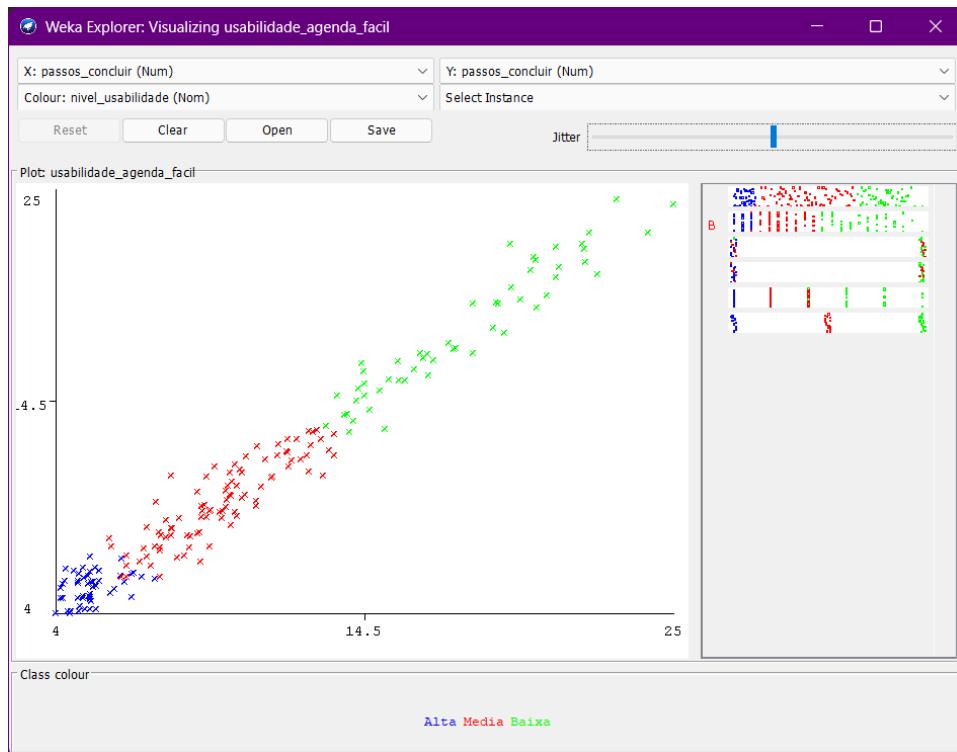
Fonte: Elaborado pelos autores (2025), a partir do software Weka.

Figura 2- Gráfico de Dispersão : tempo_agendar



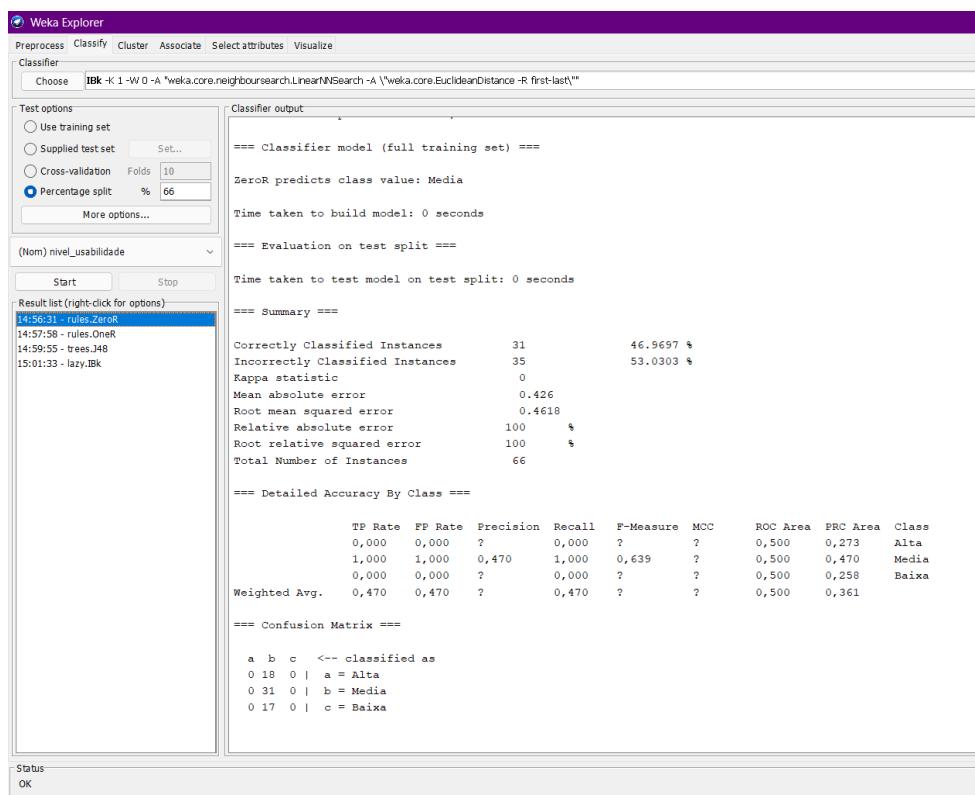
Fonte: Elaborado pelos autores (2025), a partir do software Weka.

Figura 3- Gráfico de Dispersão: passos_concluir



Fonte: Elaborado pelos autores (2025), a partir do software Weka.

Figura 4- ZeroR (Baseline)



Fonte: Elaborado pelos autores (2025), a partir do software Weka.

Figura 5- OneR (Baseline)

The screenshot shows the Weka Explorer interface with the 'Classifier' tab selected. The 'Choose' dropdown is set to 'IBk -K 1 -W 0 -A "weka.core.neighboursearch.LinearNNSearch -A "weka.core.EuclideanDistance -R first-last"'. The 'Test options' section shows 'Percentage split' at 66%. The 'Classifier output' pane displays the generated rule: < 120.5 -> Media and >= 120.5 -> Baixa, with a note '(194/195 instances correct)'. It also shows execution times and evaluation statistics for the test split, including accuracy (98.4848%), kappa statistic (0.9762), and various error metrics. A detailed accuracy table by class is provided, followed by a confusion matrix. The status bar at the bottom indicates 'OK'.

Fonte: Elaborado pelos autores (2025), a partir do software Weka.

Figura 6- Algoritmo NaiveBayes

The screenshot shows the Weka Explorer interface with the 'Classifier' tab selected. The 'Choose' dropdown is set to 'NaiveBayes'. The 'Test options' section shows 'Percentage split' at 66%. The 'Classifier output' pane displays the generated model parameters: weight sum (50, 92, 53) and precision (1, 1, 1). It also shows execution times and evaluation statistics for the test split, including accuracy (100%) and kappa statistic (1). A detailed accuracy table by class is provided, followed by a confusion matrix. The status bar at the bottom indicates 'OK'.

Fonte: Elaborado pelos autores (2025), a partir do software Weka.

Figura 7- Algoritmo IBk (k-NN)

```

Weka Explorer
Preprocess Classify Cluster Associate Select attributes Visualize
Classifier
Choose NaiveBayes
Test options
 Use training set
 Supplied test set Set...
 Cross-validation Folds 10
 Percentage split % 66
More options...
(Nom) nivel_usabilidade
Start Stop
Result list (right-click for options)
14:56:31 - rules.ZeroR
14:57:08 - rules.OneR
14:59:55 - trees.J48
15:01:23 - ibk.IBk
16:36:57 - bayes.NaiveBayes
15:01:23 - ibk.IBk
Status OK

```

IBk instance-based classifier
using 1 nearest neighbour(s) for classification

Time taken to build model: 0 seconds

==== Evaluation on test split ===

Time taken to test model on test split: 0 seconds

==== Summary ===

	Correctly Classified Instances	65	98.4848 %
Incorrectly Classified Instances	1	1.5152 %	
Kappa statistic	0.9764		
Mean absolute error	0.0192		
Root mean squared error	0.0999		
Relative absolute error	4.5132 %		
Root relative squared error	21.6284 %		
Total Number of Instances	66		

==== Detailed Accuracy By Class ===

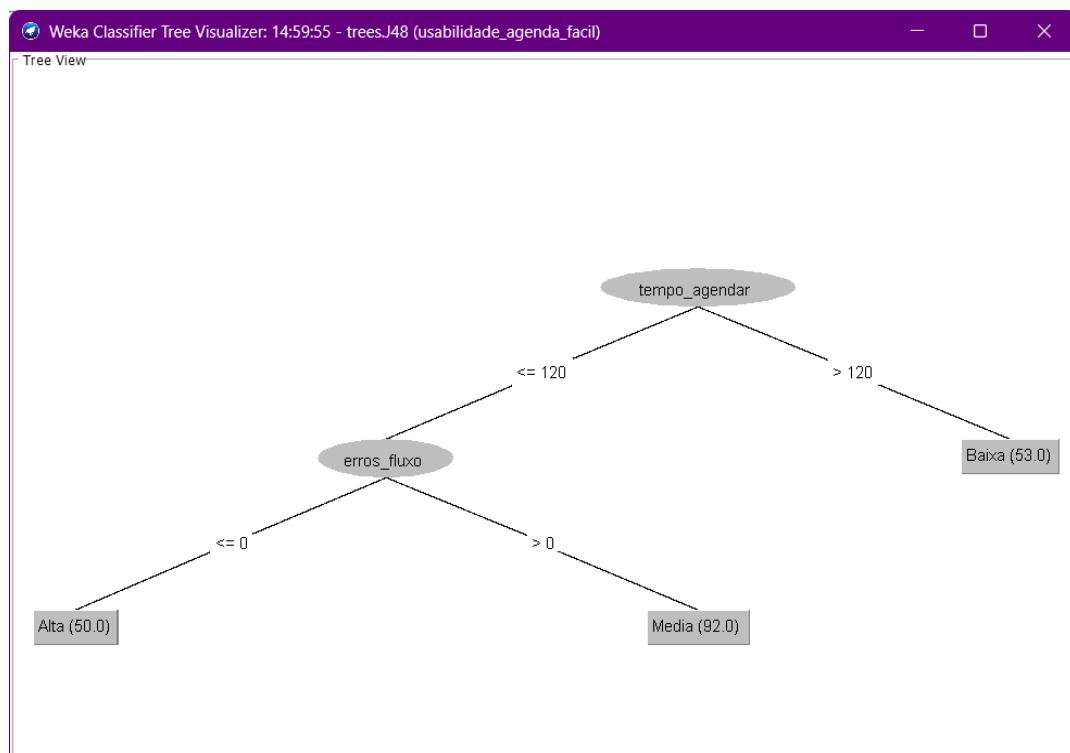
	TP	Rate	FP	Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
Alta	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	Alta
Baixa	0,968	0,000	1,000	0,968	0,984	0,970	0,987	0,984	0,984	0,984	Baixa
Media	1,000	0,020	0,944	1,000	0,971	0,962	0,990	0,944	0,944	0,944	Media
Weighted Avg.	0,985	0,005	0,986	0,985	0,985	0,976	0,991	0,978	0,978	0,978	

==== Confusion Matrix ===

a	b	c	<-- classified as
18	0	0	a = Alta
0	30	1	b = Media
0	0	17	c = Baixa

Fonte: Elaborado pelos autores (2025), a partir do software Weka.

Figura 8- J48 (Árvore de Decisão)



Fonte: Elaborado pelos autores (2025), a partir do software Weka.

10. Análise crítica dos resultados em relação ao domínio de IHC

A análise comparativa do desempenho dos modelos no conjunto de teste (66 instâncias) revelou uma alta previsibilidade dos dados, permitindo extrair conclusões significativas sobre a avaliação da experiência do usuário no domínio de IHC aplicado ao sistema "Agenda Fácil".

ZeroR (Baseline): Atingiu apenas 46,97% de acurácia. Como esperado, ele classificou todas as instâncias de teste como a classe majoritária, "Média". Isso define a linha de base: qualquer modelo útil deve superar esse valor.

OneR (Baseline): Demonstrou um salto significativo, alcançando 98,48% de acurácia. Ele errou apenas 1 das 66 instâncias, indicando que um único atributo (provavelmente tempo_agendar ou erros_fluxo) era um preditor muito forte.

IBk (k-NN): Teve um desempenho idêntico ao OneR, com 98,48% de acurácia. sua matriz de confusão mostra que também cometeu apenas um erro, classificando uma instância "Media" como "Alta".

J48 e Naive Bayes: Ambos os modelos atingiram o desempenho máximo de 100% de acurácia. Eles conseguiram classificar corretamente todas as 66 instâncias de teste sem nenhum erro.Os resultados demonstram que a usabilidade, neste contexto, não é um conceito puramente subjetivo. Pelo contrário, ela pode ser quantificada e prevista com um nível de precisão notavelmente alto. O desempenho perfeito dos algoritmos J48 e Naive Bayes indica que os atributos de interação selecionados possuem uma forte correlação com a classificação da experiência do usuário.

A análise do modelo J48 (Árvore de Decisão), que se destaca pela sua interpretabilidade, oferece os insights mais claros:

A Eficiência como Pilar Central: A árvore elegeu o atributo tempo_agendar como o nó raiz, identificando-o como o fator mais decisivo para a classificação da usabilidade. O modelo aprendeu que um tempo de tarefa superior a 120 segundos resulta, incondicionalmente, em uma classificação de usabilidade "Baixa". Isso

sugere que, para o perfil de usuário deste aplicativo, a eficiência e a velocidade na conclusão da tarefa são os principais pilares da experiência percebida.

A Eficácia como Diferencial para a Excelência: Após o critério de eficiência ser atendido ($\text{tempo} \leq 120\text{s}$), o modelo utiliza a eficácia (erros_fluxo) como o fator de desempate. A árvore demonstra que apenas as interações concluídas sem nenhum erro ($\text{erros_fluxo} \leq 0$) alcançam o nível "Alta". A ocorrência de qualquer erro ($\text{erros_fluxo} > 0$), mesmo que o tempo tenha sido satisfatório, rebaixa a classificação para "Média". Notavelmente, atributos secundários, como `usou_lista_clientes` ou `ativou_lembrete`, não foram selecionados pela árvore J48, indicando que seu impacto na classificação é irrelevante quando comparado à velocidade e à ausência de erros.

A Validação das Regras: O que o J48 "Descobriu" vs o que foi Definido. Um dos objetivos centrais do trabalho era verificar se o modelo conseguia "aprender" os padrões de usabilidade predefinidos. Ao comparar as regras originais com as extraídas da árvore de decisão J48, confirma-se que o modelo não só encontrou os padrões, como também os otimizou. Para a classe **Baixa**: A regra original era $\text{tempo_agendar} > 120$ segundos ou $\text{erros_fluxo} > 2$. O J48 aprendeu uma regra mais direta: apenas $\text{tempo_agendar} > 120$. Isso revela que o tempo de tarefa foi um indicador tão forte que se sobrepujou à necessidade de analisar os erros para identificar uma experiência ruim.

Para a classe Alta: A regra original era $\text{tempo_agendar} < 45$ segundos e $\text{erros_fluxo} = 0$. O J48 generalizou essa condição para $\text{tempo_agendar} \leq 120$ e $\text{erros_fluxo} \leq 0$. O modelo expandiu o critério de tempo, entendendo que qualquer tarefa concluída em um tempo razoável e sem erros poderia ser classificada como de alta usabilidade. Em suma, os resultados validam empiricamente que a experiência do usuário no "Agenda Fácil" é uma função direta dos dois principais pilares da usabilidade: eficiência (tempo) e eficácia (erros). Notavelmente, atributos secundários de engajamento, como `usou_lista_clientes` ou `ativou_lembrete`, não foram selecionados pela árvore J48, indicando que seu impacto na classificação da usabilidade é irrelevante quando comparado à velocidade e à ausência de erros. Para o domínio de IHC, isso comprova que um modelo de machine learning pode ser uma ferramenta poderosa de diagnóstico. Ele permite à equipe de design

focar em métricas objetivas: para otimizar a experiência do usuário deste sistema, os esforços devem ser direcionados a garantir que o fluxo da tarefa principal possa ser concluído em menos de 120 segundos e de forma tão intuitiva que minimize a ocorrência de erros.

CONCLUSÃO

Este trabalho demonstrou com sucesso a aplicabilidade de técnicas de Machine Learning na avaliação automática de usabilidade, integrando de forma prática os domínios de Interação Humano-Computador (IHC) e Aprendizado de Máquina. A partir de um cenário realista de um aplicativo de agendamentos, foi possível construir, treinar e validar modelos capazes de classificar a qualidade da experiência do usuário com base exclusivamente em métricas objetivas de interação.